


Entraînement homotopique des réseaux de neurones profonds

Joseph Gabet — L2S, CentraleSupélec

joseph.gabet@l2s.centralesupelec.fr

Contexte de l'étude

L'entraînement des réseaux de neurones profonds conduit à des problèmes d'optimisation non convexes dont la géométrie dépend du modèle, des données et de la procédure d'apprentissage. Une stratégie d'homotopie (ou continuation) consiste à ne pas attaquer directement le problème cible : on résout d'abord une version plus simple ou plus lisse, puis on réintroduit progressivement la complexité. La solution obtenue à une étape sert d'initialisation (warm start) à la suivante. Cette philosophie coarse-to-fine est attractive lorsque le problème complet présente une géométrie d'optimisation difficile, sans présumer de sa cause (non-convexité, conditionnement, bruit, distribution des données, etc.).



Objectif

Ce projet de recherche est volontairement ouvert : aucune homotopie n'est imposée. L'objectif est d'explorer comment transposer cette philosophie à l'entraînement des DNN et, surtout, de comprendre ce que signifie « simplifier progressivement » dans ce contexte. La continuation peut porter sur des quantités de nature très différente — fonction de perte, régularisation, architecture ou capacité du réseau, résolution des entrées, difficulté ou distribution des données, bruit/augmentation, contraintes, etc. — et ces choix ne reposent ni sur les mêmes hypothèses ni sur les mêmes mécanismes. Les étudiants devront formuler des idées originales, les justifier et identifier les régimes dans lesquels elles peuvent améliorer l'optimisation, la stabilité ou la généralisation par rapport à un entraînement direct.

Déroulement

- État de l'art critique.** Étudier ce qui existe déjà en deep learning (curriculum/progressive training, lissage, annealing de régularisation, changements de résolution ou de capacité, etc.) et dans des domaines où les méthodes de continuation sont bien établies, notamment en optimisation et en traitement du signal. Distinguer précisément ce qui est continué : objectif, modèle, données/distribution, résolution, contrainte ou niveau de bruit, ainsi que les hypothèses sous-jacentes.
- Conception de nouvelles homotopies.** À partir de cette cartographie, proposer une ou plusieurs stratégies originales pour des DNN : choix du paramètre de continuation, chemin entre le problème simple et le problème cible, calendrier de progression et mécanisme de warm start. Chaque proposition devra être accompagnée d'une intuition claire et de cas où un gain est attendu — ou au contraire peu plausible.
- Benchmarks convaincants.** Construire des comparaisons contrôlées avec entraînement direct et méthodes proches, à budgets de calcul/optimisation comparables. Utiliser plusieurs initialisations et, lorsque pertinent, plusieurs architectures ou distributions de données ; réaliser des ablations sur le chemin et le calendrier. Mesurer convergence, performance finale, stabilité, robustesse, coût et cas d'échec.

Outils et méthodes

Python, PyTorch (ou JAX/TensorFlow), NumPy et outils de suivi d'expériences. Les modèles et jeux de données seront choisis pour permettre de nombreuses répétitions et ablations, plutôt qu'une course à la taille.

Livrables attendus

Poster en anglais ; article de vulgarisation ; rapport scientifique ; code, scripts de benchmark et protocole expérimental reproductibles.

Références bibliographiques

- J. Gabet, M. Ferreira Da Costa, K. Lee, « Restricted Isometry for Variable-Density Continuous Frequency Sampling for Off-the-Grid Sparse Signals », Proc. IEEE ICASSP, pp. 811–815, 2026.
- Y. Bengio, J. Louradour, R. Collobert, J. Weston, « Curriculum Learning », ICML, 2009.
- E. Hazan, K. Y. Levy, S. Shalev-Shwartz, « On Graduated Optimization for Stochastic Non-Convex Problems », ICML, 2016.